Projet 1 — Analyse des journaux d'un pare-feu (Réseaux / Sécurité / IoT)

Niveau : L3 · **Durée conseillée** : 1 semaine · **Travail** : individuel · **Langage** : Python (pandas, matplotlib)

Contexte

Tu es technicien·ne sécurité dans une entreprise qui possède des PC, des serveurs et des objets connectés (caméras, capteurs). Le pare-feu a enregistré **une semaine de connexions** dans `data/logs_reseau.csv`. Ton chef te demande : *« Que s'est-il passé sur le réseau, et y a-t-il des comportements suspects ? »*

Les données

Colonne	Signification
`timestamp`	date et heure de la connexion
`src_ip` / `dst_ip`	adresse source / destination
`dst_port`	port de destination (80 = HTTP, 443 = HTTPS, 22 = SSH, 53 = DNS, 1883 = MQTT, 23 = Telnet…)
`protocol`	TCP, UDP ou ICMP
`bytes_sent`	octets envoyés
`duration_s`	durée en secondes
`device_type`	PC, serveur, camera_IoT, capteur_IoT
`action`	ALLOW (autorisé) ou DENY (bloqué)

⚠️ Le fichier est volontairement « sale » (doublons, valeurs manquantes, casse incohérente).

Ce que tu dois faire

Crée un script **`analyse.py`** (à la racine du dépôt) qui lit `data/logs_reseau.csv`, fait le nettoyage, calcule les résultats, enregistre les figures et écrit `resultats.json`. Rédige ensuite **`rapport.md`**.

1. Nettoyage

1. Supprimer les **doublons exacts**.
2. Mettre `protocol` en **MAJUSCULES**.
3. Remplacer les `bytes_sent` manquants par la **médiane** de la colonne (calculée après suppression des doublons).

2. Résultats (écrits automatiquement dans `resultats.json`)

Clé	Type	Définition
`nb_lignes_apres_nettoyage`	entier	nombre de lignes après nettoyage
`top_port`	entier	port de destination le plus fréquent
`taux_deny_pct`	décimal (2 chiffres)	pourcentage de connexions `DENY`
`ip_scanner`	texte	`src_ip` qui a contacté le plus de **ports distincts**
`ip_exfiltration`	texte	`src_ip` avec le plus grand **total** de `bytes_sent`

3. Figures (au moins 3, enregistrées en PNG dans `figures/`)

Par exemple : top des ports, connexions par heure/jour, volume d'octets par type d'appareil, répartition ALLOW/DENY. Chaque graphique doit avoir **un titre et des axes lisibles**.

4. Rapport (`rapport.md`, 1 à 2 pages)

- Résumé de ce que tu as observé (3 à 5 phrases).
- **Les 2 comportements suspects** que tu as trouvés, avec la preuve (chiffre ou graphique).
- **Au moins 3 recommandations de sécurité** concrètes (ex. : règle de pare-feu, segmentation des objets IoT, fermer Telnet…).

Rendu sur GitHub

1. Crée un dépôt **public** nommé `projet-analyse-NOM-Prenom`.
2. Pousse tout le travail (au moins **3 commits** avec des messages clairs).
3. Le dépôt doit respecter la structure ci-dessous.
4. Envoie le **lien du dépôt** au responsable de classe avec ton **nom et prénom**.

Barème (/20)

- **12 points automatiques** : structure du dépôt (3), le script s'exécute (2), les 5 résultats justes (5), les figures (2).
- **8 points qualité** : rapport et interprétation (4), qualité du code (2), historique de commits (1), recommandations (1).

Structure attendue du dépôt

```
projet-analyse-NOM-Prenom/
├── README.md          (ton nom + comment lancer le projet)
├── requirements.txt   (pandas, matplotlib…)
├── analyse.py         (se lance avec : python analyse.py)
├── rapport.md
├── resultats.json     (généré par analyse.py)
├── data/logs_reseau.csv
└── figures/*.png
```